

Análisis de Datos con R

Prof. Pedro L. Luque



Índice de contenido:

1	1. Introducción	pág. 1
1.1	¿Qué es el Análisis de Datos?	pág. 1
1.2	Tipos de Variables	pág. 2
2	2. Estadística Descriptiva	pág. 2
2.1	Medidas de Tendencia Central	pág. 2
2.2	Medidas de Dispersión	pág. 3
2.3	Visualización Gráfica	pág. 5
3	3. Correlación	pág. 6
3.1	Coefficiente de Correlación Lineal	pág. 6

1. 1. Introducción

1.1. ¿Qué es el Análisis de Datos?

El análisis de datos es el proceso de **inspeccionar**, **limpiar** y **modelar** datos con el objetivo de descubrir información útil y apoyar la toma de decisiones [1].

Entre sus etapas fundamentales destacan: - **Recolección**: obtención de datos de fuentes primarias o secundarias. - **Depuración**: tratamiento de valores faltantes y datos inconsistentes. - **Exploración**: análisis descriptivo y visualización. - **Modelado**: aplicación de técnicas estadísticas o de *machine learning*. - **Comunicación**: presentación de resultados mediante informes o dashboards.

El auge de herramientas como R y Python ha democratizado el acceso al análisis de datos. R, en particular, ofrece un ecosistema completo con paquetes como `dplyr` para manipulación y `ggplot2` para visualización [2].

Además, el paradigma de la *literate programming* —acuñado por Knuth [3]— permite integrar código, resultados y narrativa en un mismo documento, facilitando la reproducibilidad.

1.2. Tipos de Variables

Las variables se clasifican según la **naturaleza de los datos**:

Tipo	Subtipo	Ejemplos
Cualitativas	Nominales	Sexo, país, color de ojos
Cualitativas	Ordinales	Nivel de estudios, satisfacción
Cuantitativas	Discretas	Número de hijos, coches
Cuantitativas	Continuas	Altura, peso, temperatura

Es crucial identificar el tipo de variable antes de elegir el método de análisis o la representación gráfica adecuada. Un error común es tratar variables **ordinales como si fueran continuas**, lo que puede llevar a conclusiones erróneas.

2. 2. Estadística Descriptiva

2.1. Medidas de Tendencia Central

Las medidas de tendencia central resumen la distribución de los datos en un valor representativo:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{media aritmética})$$

$$M_e = \text{valor central de los datos ordenados} \quad (\text{mediana})$$

$$M_o = \text{valor con mayor frecuencia} \quad (\text{moda})$$

```
library(ggplot2)

set.seed(123)
datos <- data.frame(valor = c(rnorm(80, mean = 50, sd = 10),
                             rnorm(20, mean = 70, sd = 5)))

media <- mean(datos$valor)
mediana <- median(datos$valor)

ggplot(datos, aes(y = valor)) +
  geom_boxplot(fill = "#6699cc", alpha = 0.7) +
  geom_hline(yintercept = media, color = "#F66733", linewidth = 1,
             linetype = "dashed") +
  geom_hline(yintercept = mediana, color = "#228B22", linewidth = 1,
             linetype = "dotted") +
  labs(title = "Media y mediana en datos asimétricos",
       y = "Valor") +
  theme_minimal()
```




Figura 1: Diagrama de caja mostrando media y mediana

```
summary(datos$valor)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
26.91	45.49	52.78	54.53	64.94	80.94

En el diagrama anterior, la línea discontinua naranja representa la **media** y la línea punteada verde la **mediana**. Cuando la distribución es asimétrica, la media se desplaza hacia la cola mientras que la mediana permanece más estable.

2.2. Medidas de Dispersión

Las medidas de dispersión cuantifican la variabilidad de los datos:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (\text{varianza muestral})$$

$$s = \sqrt{s^2} \quad (\text{desviación típica})$$

$$\text{IQR} = Q_3 - Q_1 \quad (\text{rango intercuartílico})$$

```
sd(datos$valor) # desviación típica
```

```
[1] 12.1396
```

```
IQR(datos$valor)  # rango intercuartílico
```

```
[1] 19.4512
```

2.3. Visualización Gráfica

La visualización es una herramienta esencial en el análisis exploratorio de datos. El paquete `ggplot2` [4] implementa la *gramática de gráficos*, permitiendo construir visualizaciones de forma declarativa.

```
ggplot(datos, aes(x = valor)) +  
  geom_histogram(bins = 25, fill = "#3366cc", color = "white",  
                alpha = 0.85) +  
  labs(title = "Distribución de los datos",  
        x = "Valor", y = "Frecuencia") +  
  theme_minimal()
```




Figura 2: Histograma de los datos simulados

3. 3. Correlación

3.1. Coeficiente de Correlación Lineal

El coeficiente de correlación de Pearson (r) mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Sus valores oscilan entre -1 y $+1$: - $r = +1$: correlación positiva perfecta. - $r = -1$: correlación negativa perfecta. - $r \approx 0$: ausencia de relación lineal.

```
x <- rnorm(100)
y <- 0.7 * x + rnorm(100, sd = 0.5)
cor(x, y)
```

```
[1] 0.8233891
```

```
ggplot(data.frame(x, y), aes(x, y)) +
  geom_point(alpha = 0.6, size = 2, color = "#3366cc") +
  geom_smooth(method = "lm", se = TRUE,
              color = "#F66733", fill = "#F66733", alpha = 0.2) +
  labs(title = "Correlación entre dos variables simuladas") +
  theme_minimal()
```

Correlación entre dos variables simuladas




Figura 3: Diagrama de dispersión con recta de regresión

Interpretación: Un valor de $r = 0.70$ indica una **correlación positiva fuerte**. Esto significa que cuando una variable aumenta, la otra tiende a aumentar también, aunque existe una dispersión notable en torno a la recta de regresión.

Referencias

- [1] H. Wickham y G. Grolemund, *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*, First Edition. O'Reilly, 2017.
- [2] H. Wickham *et al.*, «ggplot2: Create Elegant Data Visualisations Using the Grammar of Graphics». 2019. [En línea]. Disponible en: <https://cran.r-project.org/package=ggplot2>
- [3] D. E. Knuth, «Literate Programming», *Comput. J.*, vol. 27, n.º 2, pp. 97-111, may 1984, doi: [10.1093/comjnl/27.2.97](https://doi.org/10.1093/comjnl/27.2.97).
- [4] H. Wickham, *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York, 2016. [En línea]. Disponible en: <https://ggplot2.tidyverse.org/>