

# Fundamentos de Análisis de Datos con R

Asignatura: Estadística Aplicada

---

Prof. Pedro L. Luque

2026-07-17

Universidad de Sevilla

## **Fundamentos de Análisis de Datos con R**

### 1 Introducción

1.1 ¿Qué es el Análisis de Datos?

1.2 Tipos de Variables

### 2 Estadística Descriptiva

2.1 Medidas de Tendencia Central

2.2 Medidas de Dispersión

2.3 Visualización Gráfica

### 3 Correlación

3.1 Coeficiente de Correlación Lineal

# Fundamentos de Análisis de Datos con R

# 1 Introducción

## 1.1 ¿Qué es el Análisis de Datos?

El análisis de datos es el proceso de **inspeccionar**, **limpiar** y **modelar** datos con el objetivo de descubrir información útil y apoyar la toma de decisiones [1].

Entre sus etapas fundamentales destacan:

- **Recolección:** obtención de datos de fuentes primarias o secundarias.
- **Depuración:** tratamiento de valores faltantes y datos inconsistentes.
- **Exploración:** análisis descriptivo y visualización.
- **Modelado:** aplicación de técnicas estadísticas o de *machine learning*.
- **Comunicación:** presentación de resultados mediante informes o dashboards.

El auge de herramientas como R y Python ha democratizado el acceso al análisis de datos. R, en particular, ofrece un ecosistema completo con paquetes como `dplyr` para manipulación y `ggplot2` para visualización [2].

Además, el paradigma de la *literate programming* —acuñado por Knuth [3]— permite integrar código, resultados y narrativa en un mismo documento, facilitando la reproducibilidad.

## 1.2 Tipos de Variables

Las variables se clasifican según la **naturaleza de los datos**:

| Tipo          | Subtipo   | Ejemplos                        |
|---------------|-----------|---------------------------------|
| Cualitativas  | Nominales | Sexo, país, color de ojos       |
| Cualitativas  | Ordinales | Nivel de estudios, satisfacción |
| Cuantitativas | Discretas | Número de hijos, coches         |
| Cuantitativas | Continuas | Altura, peso, temperatura       |

Es crucial identificar el tipo de variable antes de elegir el método de análisis o la representación gráfica adecuada. Un error común es tratar variables **ordinales como si fueran continuas**, lo que puede llevar a conclusiones erróneas.

## 2 Estadística Descriptiva



## 2.1 Medidas de Tendencia Central

Las medidas de tendencia central resumen la distribución de los datos en un valor representativo:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{media aritmética})$$

$M_e$  = valor central de los datos ordenados (mediana)

$M_o$  = valor con mayor frecuencia (moda)

```
library(ggplot2)

set.seed(123)
datos <- data.frame(valor = c(rnorm(80, mean = 50, sd = 10),
                             rnorm(20, mean = 70, sd = 5)))

media <- mean(datos$valor)
mediana <- median(datos$valor)

ggplot(datos, aes(y = valor)) +
```

## 2.1 Medidas de Tendencia Central

```
geom_boxplot(fill = "#6699cc", alpha = 0.7) +  
geom_hline(yintercept = media, color = "#F66733", linewidth = 1,  
           linetype = "dashed") +  
geom_hline(yintercept = mediana, color = "#228B22", linewidth = 1,  
           linetype = "dotted") +  
labs(title = "Media y mediana en datos asimétricos",  
      y = "Valor") +  
theme_minimal()
```

## 2.1 Medidas de Tendencia Central




Figura 1: Diagrama de caja mostrando media y mediana

```
summary(datos$valor)
```

|       |         |        |       |         |       |
|-------|---------|--------|-------|---------|-------|
| Min.  | 1st Qu. | Median | Mean  | 3rd Qu. | Max.  |
| 26.91 | 45.49   | 52.78  | 54.53 | 64.94   | 80.94 |

En el diagrama anterior, la línea discontinua naranja representa la **media** y la línea punteada verde la **mediana**. Cuando la distribución es asimétrica, la media se desplaza hacia la cola mientras que la mediana permanece más estable.

## 2.2 Medidas de Dispersión

Las medidas de dispersión cuantifican la variabilidad de los datos:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (\text{varianza muestral})$$

$$s = \sqrt{s^2} \quad (\text{desviación típica})$$

$$\text{IQR} = Q_3 - Q_1 \quad (\text{rango intercuartílico})$$

```
sd(datos$valor)    # desviación típica
```

```
[1] 12.1396
```

```
IQR(datos$valor)   # rango intercuartílico
```

```
[1] 19.4512
```

## 2.3 Visualización Gráfica

La visualización es una herramienta esencial en el análisis exploratorio de datos. El paquete `ggplot2` [4] implementa la *gramática de gráficos*, permitiendo construir visualizaciones de forma declarativa.

```
ggplot(datos, aes(x = valor)) +  
  geom_histogram(bins = 25, fill = "#3366cc", color = "white",  
                 alpha = 0.85) +  
  labs(title = "Distribución de los datos",  
        x = "Valor", y = "Frecuencia") +  
  theme_minimal()
```

## 2.3 Visualización Gráfica




Figura 2: Histograma de los datos simulados

## 3 Correlación



## 3.1 Coeficiente de Correlación Lineal

El coeficiente de correlación de Pearson ( $r$ ) mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$


Sus valores oscilan entre  $-1$  y  $+1$ :

- $r = +1$ : correlación positiva perfecta.
- $r = -1$ : correlación negativa perfecta.
- $r \approx 0$ : ausencia de relación lineal.

## Correlación entre dos variables

```
set.seed(42)
x_sl <- rnorm(100)
y_sl <- 0.7 * x_sl + rnorm(100, sd = 0.5)
cor(x_sl, y_sl)
```


```
[1] 0.8544287
```



## Correlación entre dos variables

```
set.seed(42)
x_sl <- rnorm(100)
y_sl <- 0.7 * x_sl + rnorm(100, sd = 0.5)
cor(x_sl, y_sl)
```

```
[1] 0.8544287
```



**Interpretación:** Un valor de  $r = 0.85$  indica una **correlación positiva fuerte**. Esto significa que cuando una variable aumenta, la otra tiende a aumentar también, aunque existe una dispersión notable en torno a la recta de regresión.

## Referencias

- [1] H. Wickham y G. Grolemund, *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*, First Edition. O'Reilly, 2017.
- [2] H. Wickham *et al.*, «ggplot2: Create Elegant Data Visualisations Using the Grammar of Graphics». 2019. [En línea]. Disponible en: <https://cran.r-project.org/package=ggplot2>
- [3] D. E. Knuth, «Literate Programming», *Comput. J.*, vol. 27, n.º 2, pp. 97-111, may 1984, doi: [10.1093/comjnl/27.2.97](https://doi.org/10.1093/comjnl/27.2.97).
- [4] H. Wickham, *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York, 2016. [En línea]. Disponible en: <https://ggplot2.tidyverse.org/>